

Ciência de Dados: Artigo Científico em Análise de Dados Aplicada

Prof. Dr. Eduardo Pena

Projeto Final

Objetivo Geral

Nesta atividade, vocês deverão desenvolver um **artigo científico com potencial de submissão** para um evento da área de banco de dados, ciência de dados, mineração de dados, aprendizado de máquina ou inteligência artificial aplicada.

O objetivo é produzir um artigo com problema bem definido, posicionamento na literatura, metodologia clara e avaliação consistente.

O trabalho final deve apresentar:

- problema analítico;
- uso de dados reais;
- diálogo com trabalhos relacionados;
- metodologia reprodutível;
- avaliação empírica consistente;
- escrita técnica bem organizada.

Tecnologias obrigatórias:

- **SQL:** PostgreSQL ou DuckDB para consultas e análise dos dados
- **Python/R:** Pandas, scikit-learn, matplotlib/seaborn/ggplot2 ou equivalentes
- **Versionamento:** Git com commits bem documentados
- **Outros:** Demais bibliotecas ou ferramentas que o grupo julgar necessárias

Grupos: Até quatro alunos.

1 Premissa Central do Projeto

O produto principal desta disciplina será um **artigo científico**. O texto final deve deixar claro qual problema está sendo estudado, qual é a contribuição do trabalho e como os resultados a sustentam.

Em particular, o artigo deve explicitar:

- qual problema está sendo estudado;
- por que esse problema é relevante;

- qual é a pergunta de pesquisa ou hipótese central;
- qual é a contribuição do trabalho;
- como o trabalho se diferencia de análises já existentes;
- quais são os principais resultados e limitações.

1.1 Tipos de contribuição aceitos

O grupo deve escolher **um eixo principal** para o artigo. Alguns exemplos:

- **Estudo empírico/aplicado:** uso de dados reais para responder perguntas relevantes e comparar abordagens analíticas ou preditivas;
- **Comparação metodológica:** comparação entre modelos, estratégias de integração, representações, consultas ou pipelines;
- **Artigo de aplicação/sistema:** desenvolvimento de uma ferramenta, pipeline, dashboard analítico ou protótipo funcional;
- **Artigo de dataset:** construção, curadoria, limpeza, integração e documentação de um conjunto de dados de interesse científico.

2 Definição do Venue-Alvo

Cada grupo deverá escolher **um venue-alvo** para o qual o trabalho seria submetido.

Essa escolha faz parte do projeto e deve ser feita logo no início, pois ela afeta o escopo do artigo, o tipo de contribuição e o formato final.

2.1 Sugestões de venues

Algumas opções particularmente relevantes para este projeto estão resumidas na Tabela 1.

Tabela 1: Venues sugeridos para orientar o artigo

Venue	Perfil	Quando faz mais sentido
KDMiLe	Mineração de dados, descoberta de conhecimento e aprendizado	Melhor opção padrão para trabalhos analíticos com foco em modelagem, comparação de métodos ou análise preditiva
BRACIS	Inteligência artificial e aplicações	Quando o foco estiver em métodos de IA/ML, experimentação mais forte ou aplicação baseada em IA
ENIAC	Inteligência artificial e computacional	Boa opção para trabalhos em IA aplicada, especialmente com caráter mais nacional e experimental
SBBB	Banco de dados, ciência de dados e gerenciamento de dados	Quando o trabalho enfatizar integração, qualidade, consultas, pipelines, modelagem de dados, recuperação ou processamento de dados
BreSci	e-science e ciência de dados	Quando o trabalho estiver ligado a dados científicos, dados abertos, infraestrutura analítica ou aplicações interdisciplinares
DSW das confs acima	Dataset showcase	Quando a principal contribuição for o dataset curado, documentado e disponibilizado para reuso
WTAG das confs acima	Trabalhos de alunos de graduação	Boa alternativa quando o grupo quiser um artigo mais enxuto e claramente caracterizado como trabalho de graduação
Demos e Aplicações das confs acima	Protótipos, sistemas e aplicações	Quando houver ferramenta, pipeline, dashboard ou sistema funcional com demonstração clara

2.2 O que deve ser definido sobre o venue

O grupo deverá entregar, já na proposta inicial:

- nome do venue escolhido;
- trilha ou tipo de submissão pretendido;
- principais adaptações exigidas pelo venue escolhido (por exemplo: limite de páginas, template, política de anonimização, formato de submissão).

3 Escolha do Dataset e Definição do Problema

Nesta etapa, o grupo deve selecionar um conjunto de dados relevante e formular um problema de pesquisa bem definido.

O dataset principal deve obrigatoriamente vir de uma das categorias da Tabela 2.

Tabela 2: Fontes permitidas para o dataset principal

Categoria	Fontes
Brasil	Dados.gov.br
Internacional	NYC Open Data, Data.gov, EU Open Data
Datasets de papers	Veja as instruções abaixo

3.1 Datasets de artigos científicos

Também é permitido usar datasets associados a artigos científicos publicados em venues de qualidade. Nessa modalidade, o grupo deve selecionar um trabalho recente, compreender o problema estudado e desenvolver uma investigação própria a partir dos dados.

O objetivo **não é replicar o artigo original**. O objetivo é usar o dataset como ponto de partida para novas perguntas, novas hipóteses, novas comparações ou uma análise complementar.

Dê preferência a artigos publicados de 2020 em diante.

3.2 O que se espera do problema escolhido

O problema escolhido deve ser relevante, viável com os dados disponíveis e específico o suficiente para sustentar o artigo.

3.3 Perguntas de pesquisa e hipóteses

O grupo deve definir:

- **1 a 2 perguntas de pesquisa** bem formuladas;
- **2 a 3 hipóteses testáveis**, quando fizer sentido.

As hipóteses não precisam existir em todos os tipos de artigo. Em trabalhos de sistema, ferramenta ou dataset, elas podem ser substituídas por **objetivos de avaliação** bem definidos.

Exemplos:

- *Quais fatores estão mais associados à evasão escolar em determinada rede de ensino?*
- *Uma fonte externa de contexto melhora a qualidade preditiva do modelo?*
- *Um pipeline com integração e limpeza explícitas produz resultados mais confiáveis do que uma abordagem direta?*
- *O dataset construído permite responder perguntas que antes eram difíceis de investigar?*

4 Escopo Técnico Mínimo

O projeto deve gerar evidência suficiente para sustentar o artigo.

4.1 Expectativas mínimas

As expectativas mínimas do projeto estão resumidas na Tabela 3.

Tabela 3: Expectativas mínimas do projeto

Aspecto	Expectativa
Dados	Dataset real, com tamanho e complexidade adequados ao problema
Reprodutibilidade	Código organizado, etapas documentadas e resultados reproduzíveis
Preparação dos dados	Limpeza, padronização e transformações justificadas
Consultas/extração	Uso de SQL em parte relevante do processo analítico
Avaliação	Resultados quantitativos e/ou qualitativos consistentes com o tipo de artigo
Comparação	Pelo menos um baseline, alternativa comparativa ou referência de comparação
Discussão	Interpretação crítica dos resultados, incluindo limitações
Artefatos	Repositório Git organizado; dataset, scripts e notebooks quando permitido

4.2 Sobre integração com fontes externas

A integração o dataset com fontes externas deve ser usada quando fizer sentido para o problema e para a avaliação do artigo.

Se houver integração, o grupo deve justificar:

- por que a fonte adicional é útil;
- como os dados foram alinhados;
- quais dificuldades surgiram;
- como a integração afetou os resultados.

5 Requisitos Científicos do Artigo

5.1 Estrutura esperada

O artigo final deve incluir, no mínimo, as seções abaixo:

1. Introdução
2. Trabalhos relacionados
3. Dados e definição do problema
4. Metodologia
5. Configuração experimental
6. Resultados e discussão
7. Limitações ou ameaças à validade
8. Conclusão

Dependendo do tipo de contribuição, o artigo também pode incluir:

- descrição do sistema ou protótipo;
- seção específica sobre curadoria do dataset;
- seção sobre disponibilidade de artefatos;
- seção sobre implicações práticas.

5.2 Trabalhos relacionados

Na seção de trabalhos relacionados, o grupo deve mostrar como o artigo se posiciona em relação ao que já existe.

Em particular, o texto deve deixar claro:

- o que já foi feito;
- onde seu trabalho se encaixa;
- em que ele difere de abordagens existentes.

5.3 Rigor experimental

Quando houver avaliação quantitativa, o artigo deve explicitar:

- as métricas utilizadas;
- a separação entre treino, validação e teste, quando aplicável;
- os cuidados para evitar *data leakage*;
- os baseline(s) usados na comparação;
- os principais parâmetros e decisões metodológicas;
- a análise dos resultados;
- análise de erro, ablação ou discussão de casos difíceis, quando fizer sentido.

6 Entregas Parciais

6.1 Etapa 1: Proposta do Artigo

Entregável: PDF de 2 páginas

A Tabela 4 resume os elementos obrigatórios da proposta inicial.

Tabela 4: Itens obrigatórios da proposta inicial

Item
Identificação do grupo e link do repositório Git
Venue-alvo escolhido e justificativa
Tipo de contribuição pretendida
Descrição do dataset principal
Problema e contexto
1–2 perguntas de pesquisa
2–3 hipóteses ou objetivos de avaliação
Lista inicial de trabalhos relacionados

Os critérios de avaliação da Etapa 1 estão na Tabela 5.

Tabela 5: Critérios de avaliação da Etapa 1

Critério
Clareza do problema
Adequação do venue escolhido
Viabilidade técnica e científica
Qualidade das perguntas de pesquisa
Potencial do projeto para virar artigo

6.2 Etapa 2: Base Experimental e Estrutura do Artigo

Entregável: Notebook documentado + esqueleto do artigo

Os elementos esperados nesta etapa aparecem na Tabela 6.

Tabela 6: Itens esperados na Etapa 2

Item
Pipeline inicial de coleta, limpeza e preparação dos dados
Consultas SQL relevantes para exploração e/ou construção do dataset analítico
Estrutura preliminar do artigo com seções definidas
Versão inicial de introdução, problema e trabalhos relacionados
Plano de avaliação experimental

Os critérios de avaliação da Etapa 2 estão na Tabela 7.

Tabela 7: Critérios de avaliação da Etapa 2

Critério
Qualidade da preparação dos dados
Organização e reprodutibilidade do pipeline
Qualidade inicial da escrita científica
Coerência entre problema, método e avaliação

6.3 Etapa 3: Resultados Parciais

Entregável: versão parcial do artigo + evidências experimentais

Os itens esperados nesta etapa estão resumidos na Tabela 8.

Tabela 8: Itens esperados na Etapa 3

Item
Resultados parciais já obtidos
Tabelas, gráficos ou figuras centrais do artigo
Comparação inicial com baseline(s) ou alternativas
Discussão preliminar dos resultados
Limitações identificadas até o momento

Os critérios de avaliação da Etapa 3 aparecem na Tabela 9.

Tabela 9: Critérios de avaliação da Etapa 3

Critério
Qualidade das evidências experimentais
Clareza dos resultados
Capacidade de interpretação crítica
Evolução do artigo em relação à proposta inicial

7 Entrega Final

7.1 Artigo Final

Entregável principal: artigo em PDF, escrito no template do venue-alvo

O artigo final deverá:

- seguir o template do venue escolhido;
- respeitar o estilo e a estrutura esperados para esse venue;
- deixar claro o tipo de contribuição do trabalho;
- apresentar dados, método, resultados e discussão com rigor;
- ter nível de organização e qualidade compatível com uma submissão.

Importante:

- Se o venue escolhido usar revisão cega, o grupo deverá adaptar a versão final para esse formato.
- O artigo da disciplina não precisa ser efetivamente submetido, mas deve ser escrito como se fosse.

7.2 Materiais adicionais

Além do artigo, o grupo deverá entregar os materiais listados na Tabela 10.

Tabela 10: Materiais adicionais da entrega final

Item
Repositório Git organizado e documentado
Código, notebooks e scripts utilizados
Dados processados ou instruções claras para reproduzi-los
Slides da apresentação

8 Critérios de Avaliação Final

Os critérios de avaliação da entrega final estão resumidos na Tabela 11.

Tabela 11: Critérios de avaliação da entrega final

Critério
Relevância e clareza do problema
Adequação do trabalho ao venue escolhido
Qualidade técnica da metodologia
Rigor da avaliação experimental
Qualidade da escrita científica
Posicionamento em relação à literatura
Interpretação crítica dos resultados
Organização e reprodutibilidade dos artefatos